Análisis 2017

STDT Ing. George Albadr

2024-11-04

```r
rm(list = ls())

knitr::opts_chunk$set(echo = TRUE, warning = FALSE, message = FALSE)
# Librerías
library(readr)
library(lubridate)
library(dplyr)
library(ggplot2)
library(tidyr)
library(scales)
library(knitr)
library(geosphere)
library(kableExtra)

# Cargar los datos
data <- read_csv("c1.csv")

# Convertir la columna 'Fecha' al formato de fecha correcto
data$Fecha <- as.Date(data$Fecha, format = "%d-%m-%y")

# Limpieza de Datos en el mismo orden

# Lista de columnas monetarias y sus nuevos nombres
monetary_columns <- c("Camion_5", "Pickup", "Moto", "factura",
                      "directoCamion_5", "directoPickup", "directoMoto",
                      "fijoCamion_5", "fijoPickup", "fijoMoto")
new_names <- c("Camion", "Pickup", "Moto", "factura",
               "directoCamion", "directoPickup", "directoMoto",
               "fijoCamion", "fijoPickup", "fijoMoto")

# Limpieza y conversión de columnas monetarias
for (i in seq_along(monetary_columns)) {
  col <- monetary_columns[i]
  new_col <- new_names[i]
  data[[col]] <- gsub("Q-", "", data[[col]])
  data[[col]] <- gsub("Q", "", data[[col]])
  data[[col]][data[[col]] == ""] <- NA
  data[[col]] <- as.numeric(data[[col]])
  colnames(data)[colnames(data) == col] <- new_col
}

# Conversión de 'x' a Booleanos para las columnas de tiempo
```

```r
time_columns <- c("5-30", "30-45", "45-75", "75-120", "120+")

for (col in time_columns) {
  data[[col]] <- ifelse(data[[col]] == "x", TRUE, FALSE)
}

# Eliminar columnas que no sirven de nada
data <- data[, !names(data) %in% c("...23", "...24", "...25", "...26", "...27", "...28")]

# Verificar la estructura de los datos
str(data)
```

```
## tibble [263,725 x 22] (S3: tbl_df/tbl/data.frame)
##  $ Fecha        : Date[1:263725], format: "2017-12-10" "2017-03-19" ...
##  $ ID           : num [1:263725] 368224 368224 368224 368224 748633 ...
##  $ Camion       : num [1:263725] NA NA NA NA NA NA NA NA NA NA ...
##  $ Pickup       : num [1:263725] 271 262 230 269 233 ...
##  $ Moto         : num [1:263725] NA NA NA NA NA NA NA NA NA NA ...
##  $ Cod          : chr [1:263725] "VERIFICACION_MEDIDORES" "REVISION_TRANSFORMADOR" "REVISION" "REVISI
##  $ origen       : num [1:263725] 150277 150277 150277 150224 150277 ...
##  $ Lat          : num [1:263725] 15.5 15.5 15.5 15.5 14.7 ...
##  $ Long         : num [1:263725] -89.7 -89.7 -89.7 -89.7 -90.9 ...
##  $ factura      : num [1:263725] 317 267 236 290 248 ...
##  $ directoCamion: num [1:263725] NA NA NA NA NA NA NA NA NA NA ...
##  $ directoPickup: num [1:263725] 168 173 136 175 154 ...
##  $ directoMoto  : num [1:263725] NA NA NA NA NA NA NA NA NA NA ...
##  $ fijoCamion   : num [1:263725] NA NA NA NA NA NA NA NA NA NA ...
##  $ fijoPickup   : num [1:263725] 102.9 89.2 94.3 94.1 79.3 ...
##  $ fijoMoto     : num [1:263725] NA NA NA NA NA NA NA NA NA NA ...
##  $ height       : num [1:263725] 8 8 8 8 8 12 12 12 10 8 ...
##  $ 5-30         : logi [1:263725] NA NA NA NA NA NA ...
##  $ 30-45        : logi [1:263725] NA NA NA NA NA NA ...
##  $ 45-75        : logi [1:263725] NA NA NA NA NA NA ...
##  $ 75-120       : logi [1:263725] NA NA NA NA NA NA ...
##  $ 120+         : logi [1:263725] TRUE TRUE TRUE TRUE TRUE TRUE ...
```

```r
## Filtrar datos del 2017
data_2017 <- data %>% filter(year(Fecha) == 2017)

# Calcular costos directos y fijos
data_2017 <- data_2017 %>%
  mutate(
    Costo_Directo = rowSums(select(., directoCamion, directoPickup, directoMoto), na.rm = TRUE),
    Costo_Fijo = rowSums(select(., fijoCamion, fijoPickup, fijoMoto), na.rm = TRUE),
    Costo_Ventas = Costo_Directo + Costo_Fijo,
    Margen_Bruto = factura - Costo_Ventas
  )

# Agregar columna del mes
data_2017$Mes <- month(data_2017$Fecha, label = TRUE, abbr = TRUE)

# Calcular ventas totales por mes
ventas_por_mes <- data_2017 %>%
  group_by(Mes) %>%
```

```r
  summarise(Ventas_Totales = sum(factura, na.rm = TRUE))

# Generar un gráfico de líneas de ventas totales por mes
ggplot(ventas_por_mes, aes(x = Mes, y = Ventas_Totales, group = 1)) +
  geom_line(color = "green", size = 1) +
  geom_point(color = "blue", size = 2) +
  labs(title = "Ventas Totales por Mes en 2017",
       x = "Mes",
       y = "Ventas Totales (Q)") +
  theme_minimal()
```

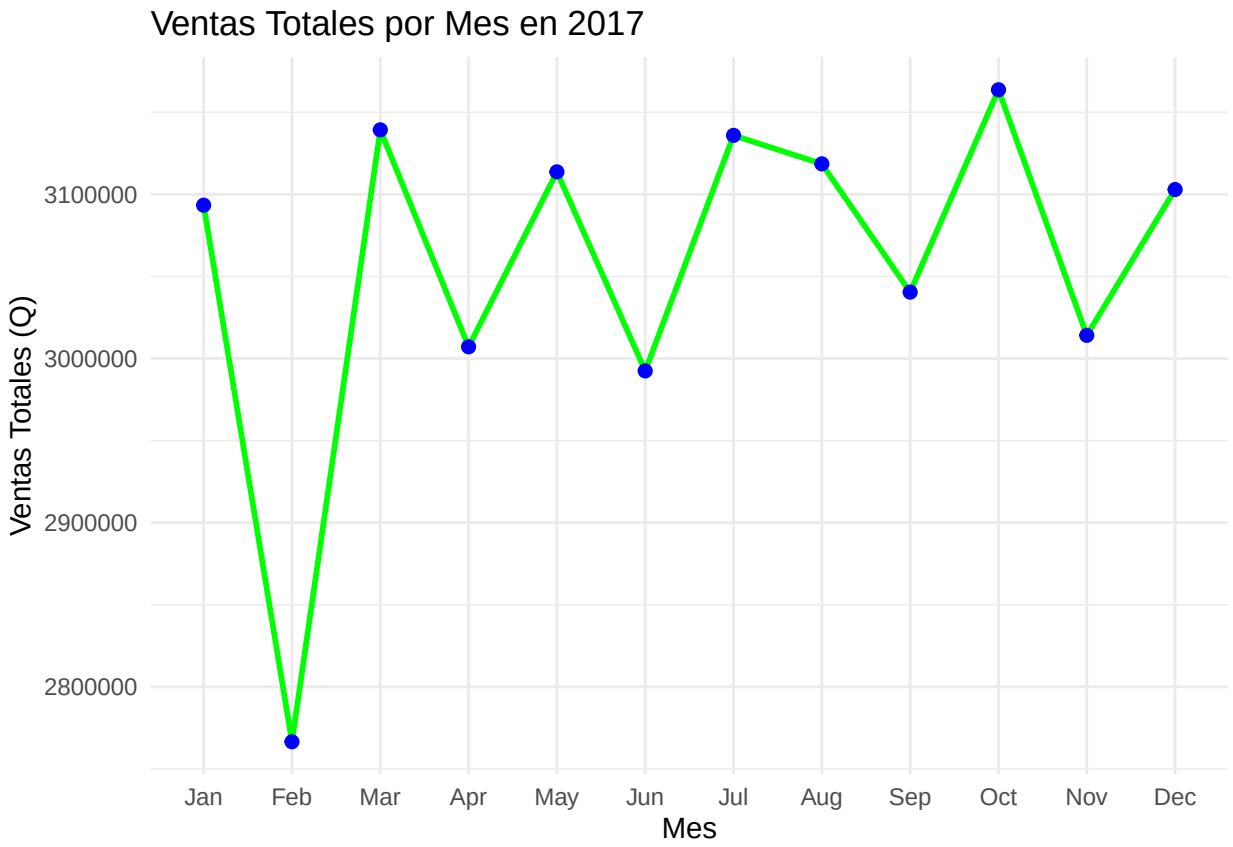


```r
# Cargar el paquete scales para formatear números
library(scales)

# Calcular ingresos por tipo de unidad
ingresos_por_unidad <- data_2017 %>%
  summarise(
    Ingreso_Camion = sum(Camion, na.rm = TRUE),
    Ingreso_Pickup = sum(Pickup, na.rm = TRUE),
    Ingreso_Moto = sum(Moto, na.rm = TRUE)
  )

# Formatear los ingresos con comas
ingresos_por_unidad_formateado <- ingresos_por_unidad %>%
  mutate(
    Ingreso_Camion = comma(Ingreso_Camion, big.mark = ","),
    Ingreso_Pickup = comma(Ingreso_Pickup, big.mark = ","),
```

```
    Ingreso_Moto = comma(Ingreso_Moto, big.mark = ",")
  )

# Mostrar ingresos por unidad
print("Ingresos por Tipo de Unidad en 2017:")
```

```
## [1] "Ingresos por Tipo de Unidad en 2017:"
```

```
print(ingresos_por_unidad_formateado)
```

```
## # A tibble: 1 x 3
##   Ingreso_Camion Ingreso_Pickup Ingreso_Moto
##   <chr>          <chr>          <chr>
## 1 8,658,363      19,121,908     393,748
```

```
# Calcular tarifas promedio por unidad
tarifa_promedio_camion <- mean(data_2017$Camion, na.rm = TRUE)
tarifa_promedio_pickup <- mean(data_2017$Pickup, na.rm = TRUE)
tarifa_promedio_moto <- mean(data_2017$Moto, na.rm = TRUE)

# Mostrar tarifas promedio formateadas con comas
print(paste("Tarifa Promedio Camión: Q", comma(round(tarifa_promedio_camion, 2))))
```

```
## [1] "Tarifa Promedio Camión: Q 139"
```

```
print(paste("Tarifa Promedio Pickup: Q", comma(round(tarifa_promedio_pickup, 2))))
```

```
## [1] "Tarifa Promedio Pickup: Q 98"
```

```
print(paste("Tarifa Promedio Moto: Q", comma(round(tarifa_promedio_moto, 2))))
```

```
## [1] "Tarifa Promedio Moto: Q 69"
```

```
# Cargar las librerías necesarias
library(dplyr)
library(tidyr)    # Necesario para pivot_longer
library(ggplot2)
library(scales)

# Verificar que 'ingresos_por_unidad' existe
if(!exists("ingresos_por_unidad")) {
  stop("El objeto 'ingresos_por_unidad' no existe. Asegúrate de que el chunk donde se define se ha ejecu
}

# Transformar los datos a formato largo para ggplot2
ingresos_long <- ingresos_por_unidad %>%
  pivot_longer(
    cols = everything(),
    names_to = "Tipo_Unidad",
    values_to = "Ingreso"
  )

# Definir colores personalizados para cada tipo de unidad
# Asegúrate de que los nombres coincidan exactamente con los de 'Tipo_Unidad'
colores_personalizados <- c(
  "Ingreso_Camion" = "#1f77b4",   # Azul
  "Ingreso_Pickup" = "#ff7f0e",  # Naranja
```

```r
  "Ingreso_Moto" = "#2ca02c"      # Verde
)

# Crear el gráfico de barras con ajustes adicionales
ggplot(ingresos_long, aes(x = Tipo_Unidad, y = Ingreso, fill = Tipo_Unidad)) +
  geom_bar(stat = "identity") +

  # Escala de colores personalizada
  scale_fill_manual(values = colores_personalizados) +

  # Escala Y con más detalles
  scale_y_continuous(
    labels = comma_format(prefix = "Q"),
    breaks = seq(0, max(ingresos_long$Ingreso) * 1.1, by = max(ingresos_long$Ingreso) / 10),
    limits = c(0, max(ingresos_long$Ingreso) * 1.1),
    expand = expansion(mult = c(0, 0.05))  # Espacio adicional en la parte superior
  ) +

  labs(
    title = "Ingresos por Tipo de Unidad en 2017",
    x = "Tipo de Unidad",
    y = "Ingreso Total (Q)"
  ) +

  theme_minimal() +

  # Remover la leyenda si no es necesaria
  theme(legend.position = "none") +

  # Agregar etiquetas de valor encima de cada barra (opcional)
  geom_text(aes(label = comma(Ingreso, big.mark = ",")),
            vjust = -0.5, size = 3.5)
```

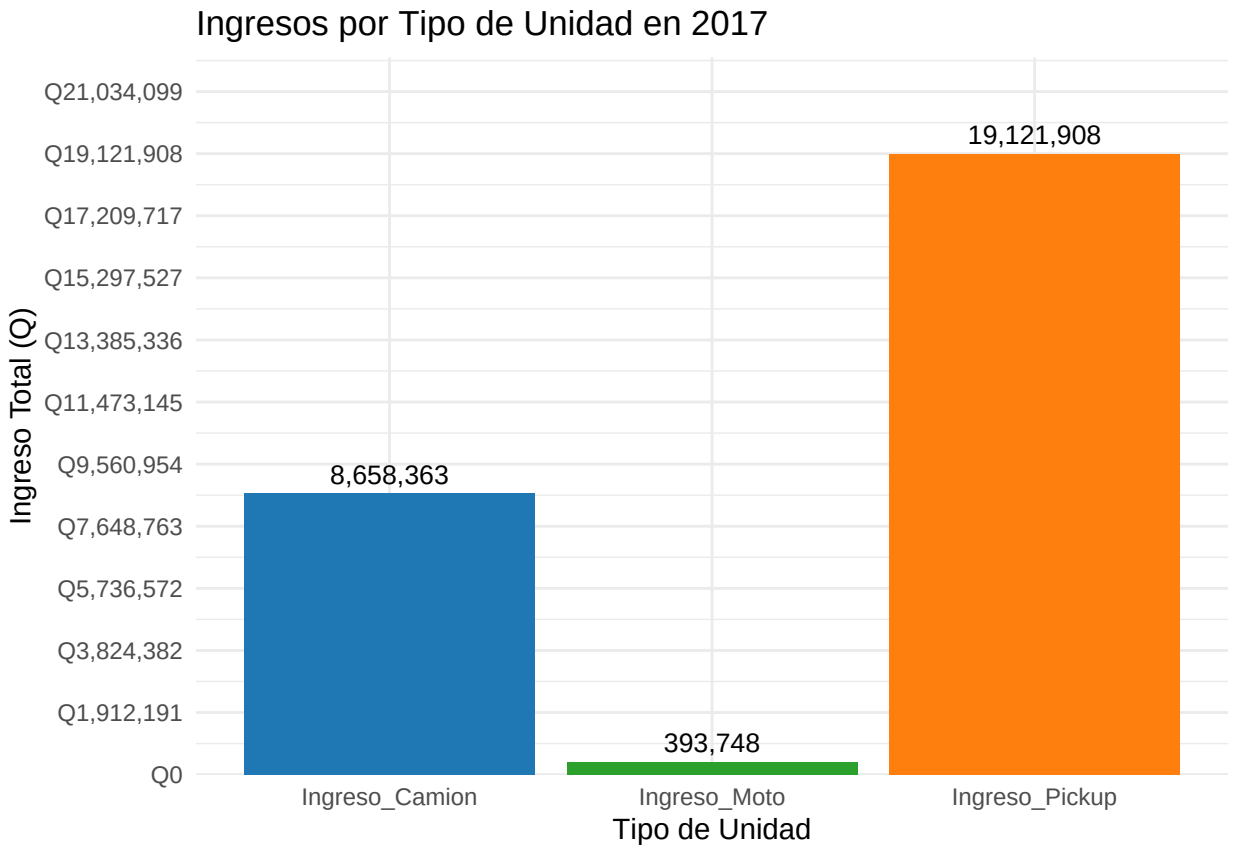


```
# Calcular el margen operativo total
margen_operativo_total <- sum(data_2017$Margen_Bruto, na.rm = TRUE)

# Verificar si estamos en números rojos
if (margen_operativo_total < 0) {
  print("La empresa está en números rojos en 2017.")
} else {
  print("La empresa tiene un margen operativo positivo en 2017.")
}
```

```
## [1] "La empresa tiene un margen operativo positivo en 2017."
```

```
print(paste("Margen Operativo Total en 2017: Q", format(round(margen_operativo_total, 2), big.mark = ",
```

```
## [1] "Margen Operativo Total en 2017: Q 8,514,077"
```

```
# Agrupar la facturación total por ID y ordenar de mayor a menor
facturacion_por_id <- data_2017 %>%
  group_by(ID) %>%
  summarise(Facturacion_Total = sum(factura, na.rm = TRUE)) %>%
  arrange(desc(Facturacion_Total)) %>%
  ungroup()

# Seleccionar los top 10 IDs con mayor facturación
top_10_ids <- facturacion_por_id %>% slice_head(n = 10)

# Convertir IDs a factor para mantener el orden en el gráfico
top_10_ids$ID <- factor(top_10_ids$ID, levels = top_10_ids$ID)
```

```r
# Cargar la librería scales para formatear los números
library(scales)

# Generar un gráfico de barras de los top 10 IDs por facturación con ejes ajustados
ggplot(top_10_ids, aes(x = ID, y = Facturacion_Total)) +
  geom_bar(stat = "identity", fill = "darkgreen") +
  labs(title = "Top 10 IDs por Facturación en 2017",
       x = "ID",
       y = "Facturación Total (Q)") +
  scale_y_continuous(
    labels = function(x) { paste0("Q", comma_format(big.mark = ",")(x)) },
    breaks = seq(0, max(top_10_ids$Facturacion_Total), by = 5000)
  ) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```

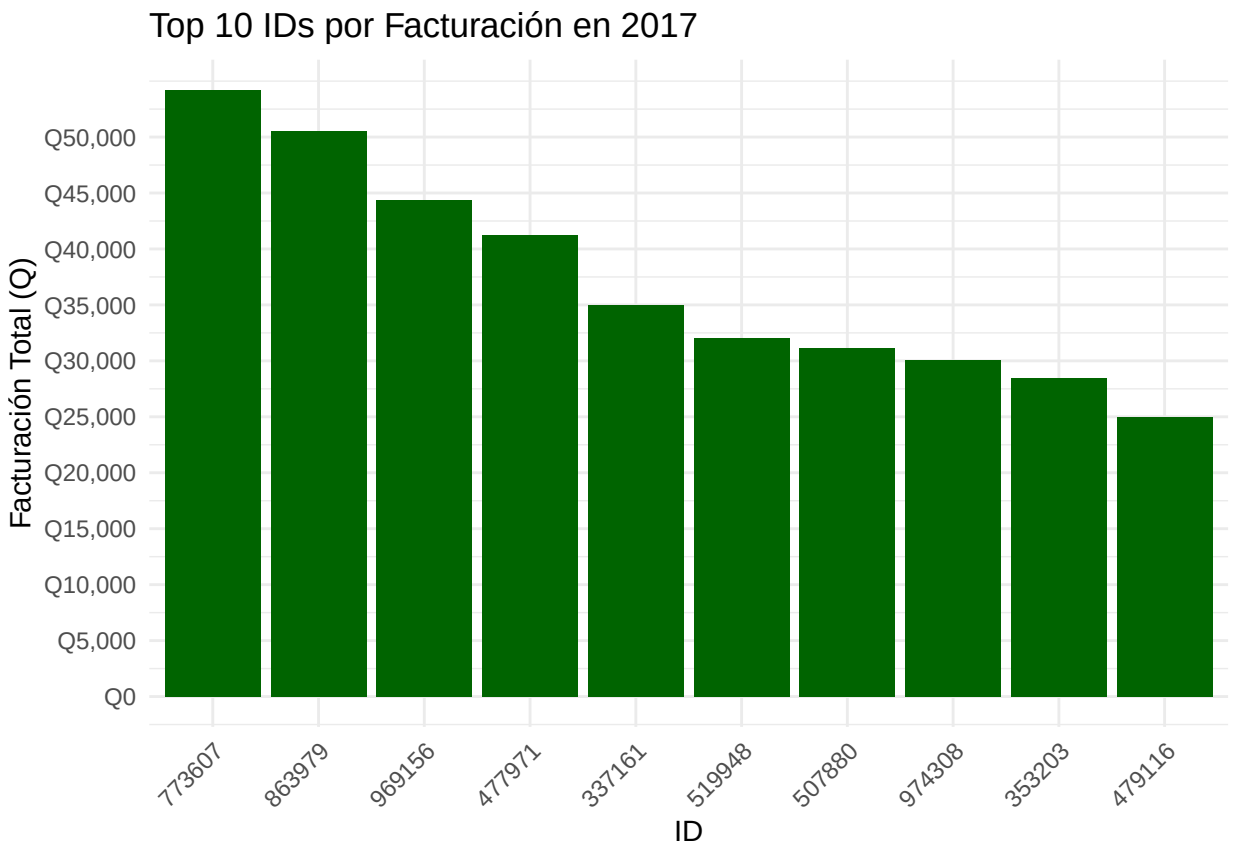


```r
# Calcular costos de mantenimiento por ID y ordenar de mayor a menor
mantenimiento_por_id <- data_2017 %>%
  group_by(ID) %>%
  summarise(Costo_Mantenimiento = sum(Costo_Ventas, na.rm = TRUE)) %>%
  arrange(desc(Costo_Mantenimiento)) %>%
  ungroup()

# Calcular el total de costos de mantenimiento
total_costo_mantenimiento <- sum(mantenimiento_por_id$Costo_Mantenimiento)

# Calcular porcentaje acumulado de costos y porcentaje acumulado de IDs
```

```r
mantenimiento_por_id <- mantenimiento_por_id %>%
  mutate(
    Porcentaje_Costo_Acum = cumsum(Costo_Mantenimiento) / total_costo_mantenimiento * 100,
    Porcentaje_ID_Acum = (row_number()) / n() * 100
  )

# Encontrar el punto donde se alcanza el 80% del costo acumulado
punto_80 <- mantenimiento_por_id %>% filter(Porcentaje_Costo_Acum >= 80) %>% slice_head(n = 1)

# Calcular el porcentaje de IDs que representan el 80% de los costos
porcentaje_ids_80 <- punto_80$Porcentaje_ID_Acum

# Gráfico de la curva de Pareto
ggplot(mantenimiento_por_id, aes(x = Porcentaje_ID_Acum, y = Porcentaje_Costo_Acum)) +
  geom_line(color = "blue", size = 1) +
  geom_vline(xintercept = porcentaje_ids_80, linetype = "dashed", color = "red") +
  geom_hline(yintercept = 80, linetype = "dashed", color = "red") +
  annotate("text", x = porcentaje_ids_80 + 5, y = 80,
           label = paste0("(", round(porcentaje_ids_80, 2), "%, 80%)"), color = "black") +
  labs(title = "Curva de Pareto de Costos de Mantenimiento",
       x = "Porcentaje Acumulado de IDs",
       y = "Porcentaje Acumulado de Costos de Mantenimiento") +
  theme_minimal()
```

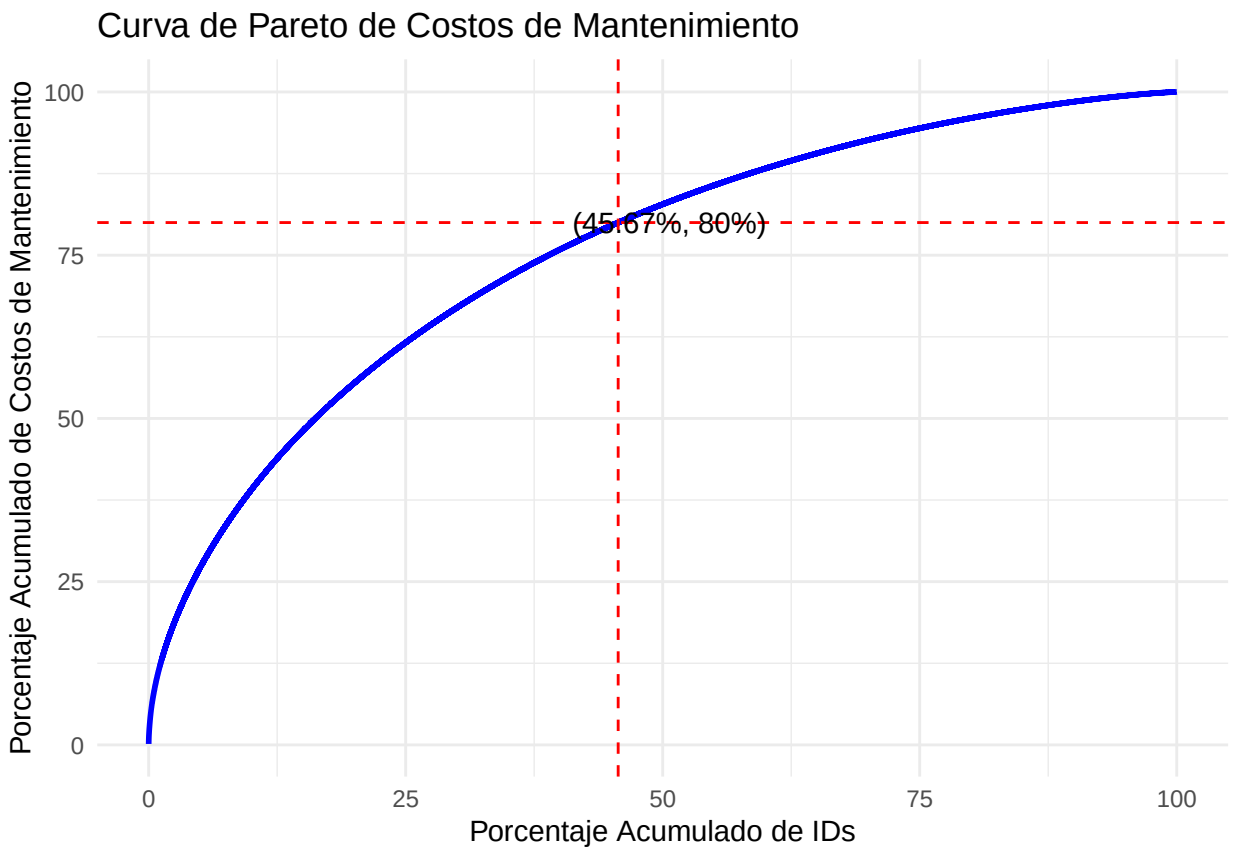


```r
# Asignar un tiempo promedio a cada rango
data_2017 <- data_2017 %>%
  mutate(
```

```
    Tiempo_Estimado = case_when(
      `5-30` == TRUE ~ 17.5,
      `30-45` == TRUE ~ 37.5,
      `45-75` == TRUE ~ 60,
      `75-120` == TRUE ~ 97.5,
      `120+` == TRUE ~ 150,
      TRUE ~ NA_real_
    )
  )

# Eliminar filas con NA en Tiempo_Estimado
data_2017_clean <- data_2017 %>%
  filter(!is.na(Tiempo_Estimado))

# Calcular estadísticas descriptivas
descriptivas <- data_2017_clean %>%
  summarise(
    Media = mean(Tiempo_Estimado, na.rm = TRUE),
    Mediana = median(Tiempo_Estimado, na.rm = TRUE),
    Moda = as.numeric(names(sort(table(Tiempo_Estimado), decreasing = TRUE)[1])),
    Desviacion_Estandar = sd(Tiempo_Estimado, na.rm = TRUE),
    Minimo = min(Tiempo_Estimado, na.rm = TRUE),
    Maximo = max(Tiempo_Estimado, na.rm = TRUE)
  )

print("Estadísticas Descriptivas de Tiempo Estimado:")
```

```
## [1] "Estadísticas Descriptivas de Tiempo Estimado:"
```

```
print(descriptivas)
```

```
## # A tibble: 1 x 6
##   Media Mediana  Moda Desviacion_Estandar Minimo Maximo
##   <dbl>   <dbl> <dbl>               <dbl>  <dbl>  <dbl>
## 1  73.9    97.5  97.5                39.8   17.5    150
```

```
# Calcular la frecuencia total para porcentajes
total_frecuencia <- sum(table(data_2017_clean$Tiempo_Estimado))

# Gráfico de distribución de tiempos estimados con porcentajes
ggplot(data_2017_clean, aes(x = Tiempo_Estimado)) +
  geom_histogram(aes(y = ..count../sum(..count..) * 100), binwidth = 10, fill = "purple", color = "blac
  geom_vline(aes(xintercept = Media), data = descriptivas, color = "blue", linetype = "dashed", size =
  geom_vline(aes(xintercept = Mediana), data = descriptivas, color = "green", linetype = "dashed", size
  geom_vline(aes(xintercept = Moda), data = descriptivas, color = "red", linetype = "dashed", size = 1)
  scale_y_continuous(labels = percent_format(scale = 1)) +
  labs(title = "Distribución de Tiempos Estimados de Recorrido en 2017",
       x = "Tiempo Estimado (minutos)",
       y = "Frecuencia (%)") +
  theme_minimal() +
  annotate("text", x = descriptivas$Media + 5, y = 90,
           label = paste("Media:", round(descriptivas$Media, 2), "%"), color = "blue", angle = 0, vjust
  annotate("text", x = descriptivas$Mediana + 5, y = 85,
           label = paste("Mediana:", round(descriptivas$Mediana, 2), "%"), color = "black", angle = 0,
  annotate("text", x = descriptivas$Moda + 5, y = 80,
```

```
          label = paste("Moda:", round(descriptivas$Moda, 2), "%"), color = "red", angle = 0, vjust =
```

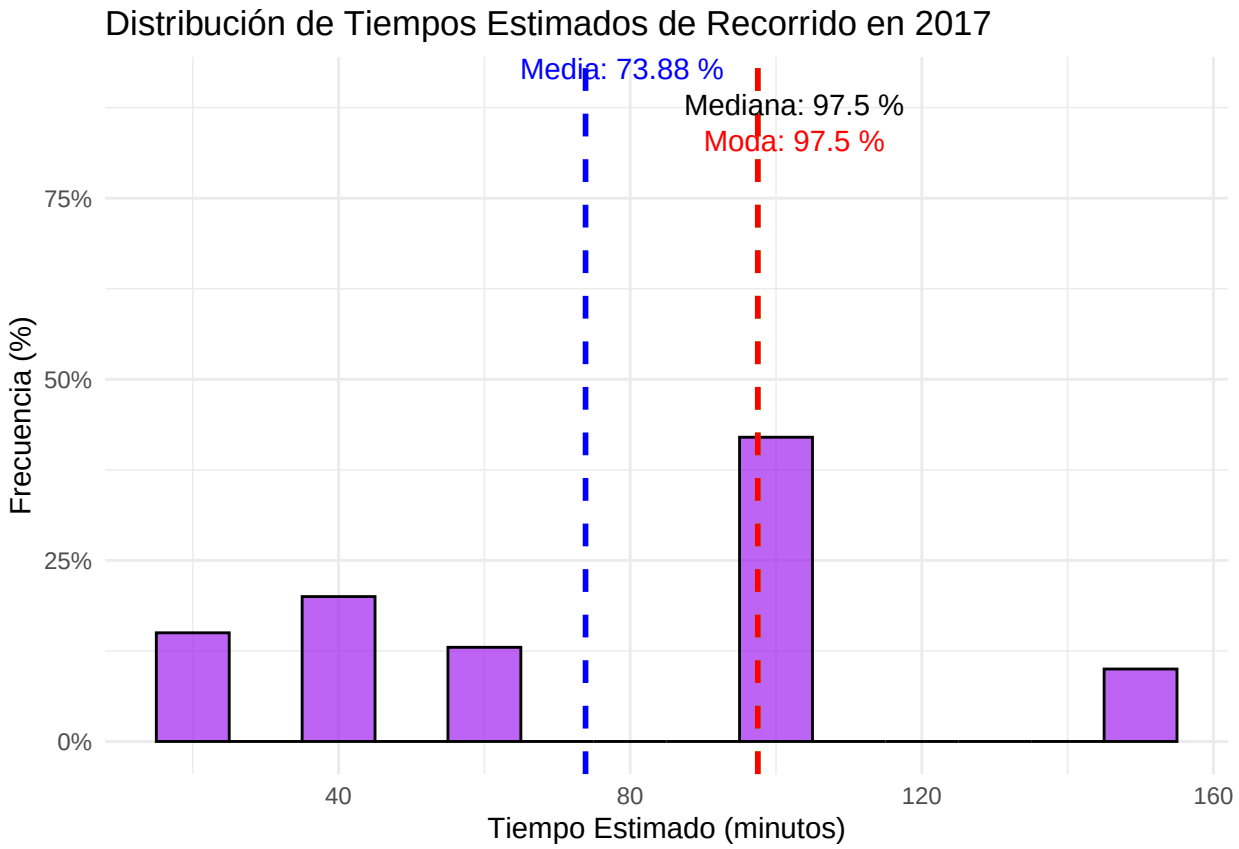

##Paso 1: Definir los Centros de Distribución

Primero, debes definir los cuatro centros de distribución con sus respectivas coordenadas (latitud y longitud). Asegúrate de reemplazar las coordenadas de ejemplo con las reales de tus centros.

```r
# Definir los centros de distribución con coordenadas reales utilizando k-means clustering
# Seleccionar las columnas de latitud y longitud, asegurando que sean numéricas y sin NA
coords <- data_2017 %>%
  select(Lat, Long) %>%
  filter(!is.na(Lat) & !is.na(Long))

# Verificar el número de centros a crear
k <- 4  # Número de centros de distribución

# Realizar clustering con k-means para identificar 4 centros
set.seed(123)  # Para reproducibilidad
kmeans_result <- kmeans(coords, centers = k, nstart = 25)

# Crear dataframe de centros de distribución basados en los centros del clustering
centros_distribucion <- data.frame(
  Centro = paste0("Centro", 1:k),
  Lat = round(kmeans_result$centers[, "Lat"], 6),
  Long = round(kmeans_result$centers[, "Long"], 6)
)

# Mostrar los centros de distribución
```

```r
kable(centros_distribucion, caption = "Centros de Distribución Identificados con sus Coordenadas Reales
  kable_styling(full_width = FALSE, position = "center")
```

Table 1: Centros de Distribución Identificados con sus Coordenadas Reales

Centro	Lat	Long
Centro1	15.50703	-90.49530
Centro2	14.49850	-90.50241
Centro3	14.49200	-89.50516
Centro4	15.48897	-89.49332

##Paso 2: Asignar Servicios al Centro de Distribución Más Cercano

Utilizaremos la función distHaversine del paquete geosphere para calcular la distancia entre cada servicio y los centros de distribución, asignando cada servicio al centro más cercano.

```r
# Asegurarse de que las columnas Lat y Long son numéricas
data_2017 <- data_2017 %>%
  mutate(
    Lat = as.numeric(Lat),
    Long = as.numeric(Long)
  )

# Función para asignar cada servicio al centro más cercano
asignar_centro <- function(lat, long, centros) {
  # Crear una matriz de coordenadas para el servicio
  servicio_coord <- c(long, lat)

  # Crear una matriz de coordenadas para los centros
  centros_coords <- as.matrix(centros[, c("Long", "Lat")])

  # Calcular distancias a todos los centros (en metros)
  distancias <- distHaversine(servicio_coord, centros_coords)

  # Retornar el nombre del centro más cercano
  centros$Centro[which.min(distancias)]
}

# Asignar centro a cada servicio
data_2017 <- data_2017 %>%
  rowwise() %>%
  mutate(Centro_Distribucion = asignar_centro(Lat, Long, centros_distribucion)) %>%
  ungroup()

# Verificar la asignación de servicios a cada centro
frecuencia_centros <- data_2017 %>%
  group_by(Centro_Distribucion) %>%
  summarise(
    Numero_Servicios = n(),
    Porcentaje_Servicios = round((n() / nrow(data_2017)) * 100, 2)
  )
```

```r
# Formatear las cifras
frecuencia_centros <- frecuencia_centros %>%
  mutate(
    Numero_Servicios = comma(Numero_Servicios, big.mark = ","),
    Porcentaje_Servicios = paste0(Porcentaje_Servicios, "%")
  )

# Mostrar la tabla de asignación
kable(frecuencia_centros,
      caption = "Frecuencia de Servicios por Centro de Distribución") %>%
  kable_styling(full_width = FALSE, position = "center")
```

Table 2: Frecuencia de Servicios por Centro de Distribución

Centro_Distribucion	Numero_Servicios	Porcentaje_Servicios
Centro1	65,031	24.66%
Centro2	66,470	25.2%
Centro3	65,561	24.86%
Centro4	66,663	25.28%

###Paso 3: Resumir el Margen Bruto por Centro de Distribución

Generaremos una tabla que resume el Total de Margen Bruto, el Número de Servicios y el Margen Promedio por cada centro de distribución.

```r
# Calcular total y margen promedio por centro
margen_por_centro <- data_2017 %>%
  group_by(Centro_Distribucion) %>%
  summarise(
    Total_Margen_Bruto = sum(Margen_Bruto, na.rm = TRUE),
    Servicios = n(),
    Margen_Promedio = mean(Margen_Bruto, na.rm = TRUE)
  ) %>%
  mutate(
    Total_Margen_Bruto = comma(Total_Margen_Bruto, big.mark = ","),
    Margen_Promedio = comma(round(Margen_Promedio, 2), big.mark = ",")
  )

# Mostrar la tabla formateada
kable(margen_por_centro,
      caption = "Resumen del Margen Bruto por Centro de Distribución") %>%
  kable_styling(full_width = FALSE, position = "center")
```

Table 3: Resumen del Margen Bruto por Centro de Distribución

Centro_Distribucion	Total_Margen_Bruto	Servicios	Margen_Promedio
Centro1	2,097,066	65031	32.25
Centro2	2,148,871	66470	32.33
Centro3	2,126,025	65561	32.43
Centro4	2,142,116	66663	32.13

##verificacion

```r
# Inspeccionar una muestra de asignaciones
muestra_asignacion <- data_2017 %>%
  select(ID, Lat, Long, Centro_Distribucion) %>%
  slice_head(n = 20)

# Mostrar la muestra
kable(muestra_asignacion,
      caption = "Muestra de Asignación de Servicios a Centros de Distribución") %>%
  kable_styling(full_width = FALSE, position = "center")
```

Table 4: Muestra de Asignación de Servicios a Centros de Distribución

ID	Lat	Long	Centro_Distribucion
368224	15.46333	-89.72565	Centro4
368224	15.46333	-89.72565	Centro4
368224	15.46333	-89.72565	Centro4
368224	15.46333	-89.72565	Centro4
748633	14.72568	-90.89644	Centro2
599434	15.93645	-89.04138	Centro4
599434	15.93645	-89.04138	Centro4
599434	15.93645	-89.04138	Centro4
790749	15.95877	-90.89046	Centro1
760915	14.39340	-90.54944	Centro2
760915	14.39340	-90.54944	Centro2
576258	15.20378	-90.81217	Centro1
814417	14.43319	-90.38244	Centro2
449894	15.62738	-90.16696	Centro1
565298	14.46072	-90.79400	Centro2
460650	14.07410	-89.95981	Centro3
730040	14.95062	-89.89759	Centro3
730040	14.95062	-89.89759	Centro3
730040	14.95062	-89.89759	Centro3
730040	14.95062	-89.89759	Centro3

```r
# Recalcular y formatear el resumen del margen bruto por centro
margen_por_centro <- data_2017 %>%
  group_by(Centro_Distribucion) %>%
  summarise(
    Total_Margen_Bruto = sum(Margen_Bruto, na.rm = TRUE),
    Servicios = n(),
    Margen_Promedio = mean(Margen_Bruto, na.rm = TRUE)
  ) %>%
  mutate(
    Total_Margen_Bruto = comma(Total_Margen_Bruto, big.mark = ","),
    Margen_Promedio = comma(round(Margen_Promedio, 2), big.mark = ",")
  )

# Mostrar la tabla formateada
kable(margen_por_centro,
      caption = "Resumen del Margen Bruto por Centro de Distribución") %>%
```

```
  kable_styling(full_width = FALSE, position = "center")
```

Table 5: Resumen del Margen Bruto por Centro de Distribución

Centro_Distribucion	Total_Margen_Bruto	Servicios	Margen_Promedio
Centro1	2,097,066	65031	32.25
Centro2	2,148,871	66470	32.33
Centro3	2,126,025	65561	32.43
Centro4	2,142,116	66663	32.13

##Tabla de estrategias

```
# Crear una tabla de estrategias
estrategias <- data.frame(
  Estrategia = c(
    "Optimizar Centros con Alto Margen Bruto",
    "Reducir Costos en Centros con Bajo Margen Bruto",
    "Redistribuir Servicios",
    "Implementar Programas de Fidelización",
    "Monitorear y Evaluar Continuamente"
  ),
  Accion = c(
    "Analizar y replicar mejores prácticas en todos los centros.",
    "Identificar y eliminar costos innecesarios.",
    "Equilibrar la carga de trabajo entre centros.",
    "Fomentar la lealtad de clientes en centros clave.",
    "Establecer KPIs y realizar seguimiento regular."
  ),
  Impacto_Esperado = c(
    "Aumento de la eficiencia y márgenes en todos los centros.",
    "Incremento en los márgenes brutos mediante la reducción de costos.",
    "Mejor utilización de recursos y mayor eficiencia operativa.",
    "Incremento en ventas y márgenes brutos.",
    "Capacidad de mantener y mejorar márgenes brutos."
  )
)

# Mostrar la tabla de estrategias
kable(estrategias,
      caption = "Estrategias para Aumentar el Margen Bruto por Centro de Distribución") %>%
  kable_styling(full_width = FALSE, position = "center")
```

Table 6: Estrategias para Aumentar el Margen Bruto por Centr
de Distribución

Estrategia	Accion	Impacto
Optimizar Centros con Alto Margen Bruto	Analizar y replicar mejores prácticas en todos los centros.	Aumento
Reducir Costos en Centros con Bajo Margen Bruto	Identificar y eliminar costos innecesarios.	Increme
Redistribuir Servicios	Equilibrar la carga de trabajo entre centros.	Mejor u
Implementar Programas de Fidelización	Fomentar la lealtad de clientes en centros clave.	Increme
Monitorear y Evaluar Continuamente	Establecer KPIs y realizar seguimiento regular.	Capacid

```r
# Identificar servicios con margen bruto negativo
servicios_perdida <- data_2017 %>% filter(Margen_Bruto < 0)

# Número y porcentaje de servicios con pérdidas
num_servicios_perdida <- nrow(servicios_perdida)
total_servicios <- nrow(data_2017)
porcentaje_perdida <- (num_servicios_perdida / total_servicios) * 100

print(paste("Número de servicios con margen bruto negativo:", num_servicios_perdida))
```

```
## [1] "Número de servicios con margen bruto negativo: 0"
```

```r
print(paste("Porcentaje de servicios con pérdidas:", round(porcentaje_perdida, 2), "%"))
```

```
## [1] "Porcentaje de servicios con pérdidas: 0 %"
```

En esta parte realizamos un analisis de la acoplacion de un programa de fidelizacion con el objetivo de aumentar las ventas actuales netas en un 10% brindando un 2% de descuento en el total de ventas para incentivar aun mas a los clientes.

```r
# Actualizamos los datos de los top 10 IDs
top_10_ids <- top_10_ids %>%
  mutate(
    Ventas_Actuales = Facturacion_Total,
    Incremento_Ventas = Ventas_Actuales * 0.10,
    Ventas_Nuevas = Ventas_Actuales + Incremento_Ventas,
    Descuento = Ventas_Nuevas * 0.02,
    Facturacion_Despues_Descuento = Ventas_Nuevas - Descuento,
    Costo_Ventas_Actual = Ventas_Actuales * 0.70,
    Costo_Ventas_Nuevo = Ventas_Nuevas * 0.70,
    Margen_Bruto_Actual = Ventas_Actuales - Costo_Ventas_Actual,
    Margen_Bruto_Nuevo = Facturacion_Despues_Descuento - Costo_Ventas_Nuevo,
    Diferencia_Margen_Bruto = Margen_Bruto_Nuevo - Margen_Bruto_Actual
  )

# Formateamos las columnas numéricas con comas
top_10_ids_formateado <- top_10_ids %>%
  mutate_at(vars(Ventas_Actuales, Ventas_Nuevas, Margen_Bruto_Actual, Margen_Bruto_Nuevo, Diferencia_Ma

# Mostrar los resultados
top_10_ids_formateado %>%
  select(ID, Ventas_Actuales, Ventas_Nuevas, Margen_Bruto_Actual, Margen_Bruto_Nuevo, Diferencia_Margen_
```

```
## # A tibble: 10 x 6
##    ID     Ventas_Actuales Ventas_Nuevas Margen_Bruto_Actual Margen_Bruto_Nuevo
##    <fct>  <chr>           <chr>         <chr>               <chr>
##  1 773607 54,202          59,623        16,261              16,694
##  2 863979 50,494          55,544        15,148              15,552
##  3 969156 44,404          48,845        13,321              13,677
##  4 477971 41,224          45,346        12,367              12,697
##  5 337161 34,991          38,490        10,497              10,777
```

```
##  6 519948 32,008          35,209        9,602               9,858
##  7 507880 31,123          34,235        9,337               9,586
##  8 974308 30,087          33,096        9,026               9,267
##  9 353203 28,458          31,303        8,537               8,765
## 10 479116 24,938          27,432        7,481               7,681
## # i 1 more variable: Diferencia_Margen_Bruto <chr>
```

Aqui se habla de como un imacto en una economia a escala y reduccion del 5% del costo de ventas al margen bruto en general

```
#Supongamos que el costo de ventas disminuye al 65% debido a economias de escala

# Actualizamos el costo de ventas nuevo
top_10_ids <- top_10_ids %>%
  mutate(
    Costo_Ventas_Nuevo = Ventas_Nuevas * 0.65
  )

# Recalculamos el Margen Bruto Nuevo y la Diferencia del Margen Bruto
top_10_ids <- top_10_ids %>%
  mutate(
    Margen_Bruto_Nuevo = Facturacion_Despues_Descuento - Costo_Ventas_Nuevo,
    Diferencia_Margen_Bruto = Margen_Bruto_Nuevo - Margen_Bruto_Actual
  )

# Formateamos las columnas numéricas con comas
top_10_ids_formateado <- top_10_ids %>%
  mutate_at(vars(Ventas_Actuales, Ventas_Nuevas, Margen_Bruto_Actual, Margen_Bruto_Nuevo, Diferencia_Ma

# Mostrar los resultados actualizados
top_10_ids_formateado %>%
  select(ID, Ventas_Actuales, Ventas_Nuevas, Margen_Bruto_Actual, Margen_Bruto_Nuevo, Diferencia_Margen_
```

```
## # A tibble: 10 x 6
##    ID     Ventas_Actuales Ventas_Nuevas Margen_Bruto_Actual Margen_Bruto_Nuevo
##    <fct>  <chr>           <chr>         <chr>               <chr>
##  1 773607 54,202          59,623        16,261              19,675
##  2 863979 50,494          55,544        15,148              18,329
##  3 969156 44,404          48,845        13,321              16,119
##  4 477971 41,224          45,346        12,367              14,964
##  5 337161 34,991          38,490        10,497              12,702
##  6 519948 32,008          35,209        9,602               11,619
##  7 507880 31,123          34,235        9,337               11,298
##  8 974308 30,087          33,096        9,026               10,922
##  9 353203 28,458          31,303        8,537               10,330
## 10 479116 24,938          27,432        7,481               9,052
## # i 1 more variable: Diferencia_Margen_Bruto <chr>
```

Aqui se hablade posibles ecenarios en el incremento de y descuentos de ventas en margen bruto para los clientes para ver mas opciones para aumentar le margen bruto.

```r
# Definir la función probar_escenario sin formatear
probar_escenario <- function(incremento_ventas_pct, descuento_pct, costo_ventas_pct_actual, costo_ventas
  top_10_ids %>%
    mutate(
      Ventas_Actuales = Facturacion_Total,
      Incremento_Ventas = Ventas_Actuales * incremento_ventas_pct,
      Ventas_Nuevas = Ventas_Actuales + Incremento_Ventas,
      Descuento = Ventas_Nuevas * descuento_pct,
      Facturacion_Despues_Descuento = Ventas_Nuevas - Descuento,
      Costo_Ventas_Actual = Ventas_Actuales * costo_ventas_pct_actual,
      Costo_Ventas_Nuevo = Ventas_Nuevas * costo_ventas_pct_nuevo,
      Margen_Bruto_Actual = Ventas_Actuales - Costo_Ventas_Actual,
      Margen_Bruto_Nuevo = Facturacion_Despues_Descuento - Costo_Ventas_Nuevo,
      Diferencia_Margen_Bruto = Margen_Bruto_Nuevo - Margen_Bruto_Actual
    ) %>%
    summarise(
      Total_Margen_Bruto_Actual = sum(Margen_Bruto_Actual),
      Total_Margen_Bruto_Nuevo = sum(Margen_Bruto_Nuevo),
      Diferencia_Total_Margen_Bruto = sum(Diferencia_Margen_Bruto)
    )
}

# Crear un data frame con diferentes combinaciones
escenarios <- expand.grid(
  Incremento_Ventas_Pct = seq(0.10, 0.50, by = 0.05),
  Descuento_Pct = seq(0.01, 0.05, by = 0.01),
  Costo_Ventas_Pct_Nuevo = c(0.70, 0.68, 0.65)
)

# Añadir columnas para almacenar los resultados
resultados <- escenarios %>%
  rowwise() %>%
  mutate(
    Resultado = list(probar_escenario(Incremento_Ventas_Pct, Descuento_Pct, 0.70, Costo_Ventas_Pct_Nuev
  ) %>%
  unnest(Resultado, names_repair = "unique")  # Evita duplicación de nombres

# Formatear las columnas numéricas con comas y evitar notación científica
resultados <- resultados %>%
  mutate(
    Total_Margen_Bruto_Actual = comma(Total_Margen_Bruto_Actual, big.mark = ","),
    Total_Margen_Bruto_Nuevo = comma(Total_Margen_Bruto_Nuevo, big.mark = ","),
    Diferencia_Total_Margen_Bruto = comma(Diferencia_Total_Margen_Bruto, big.mark = ",")
  )

# Convertir los porcentajes a formato de porcentaje
resultados <- resultados %>%
  mutate(
    Incremento_Ventas_Pct = percent(Incremento_Ventas_Pct),
```

```
    Descuento_Pct = percent(Descuento_Pct),
    Costo_Ventas_Pct_Nuevo = percent(Costo_Ventas_Pct_Nuevo)
  )

# Seleccionar y reorganizar las columnas para mostrar los resultados
resultados_mostrados <- resultados %>%
  select(
    Incremento_Ventas_Pct,
    Descuento_Pct,
    Costo_Ventas_Pct_Nuevo,
    Total_Margen_Bruto_Actual,
    Total_Margen_Bruto_Nuevo,
    Diferencia_Total_Margen_Bruto
  )

# Mostrar los escenarios donde la diferencia en margen bruto es positiva y ordenados
resultados_mostrados %>%
  filter(as.numeric(gsub(",", "", Diferencia_Total_Margen_Bruto)) > 0) %>%
  arrange(desc(as.numeric(gsub(",", "", Diferencia_Total_Margen_Bruto)))) %>%
  print()
```

```
## # A tibble: 128 x 6
##    Incremento_Ventas_Pct Descuento_Pct Costo_Ventas_Pct_Nuevo
##    <chr>                 <chr>         <chr>
##  1 50%                   1%            65%
##  2 50%                   2%            65%
##  3 45%                   1%            65%
##  4 50%                   3%            65%
##  5 45%                   2%            65%
##  6 40%                   1%            65%
##  7 50%                   1%            68%
##  8 50%                   4%            65%
##  9 45%                   3%            65%
## 10 40%                   2%            65%
## # i 118 more rows
## # i 3 more variables: Total_Margen_Bruto_Actual <chr>,
## #   Total_Margen_Bruto_Nuevo <chr>, Diferencia_Total_Margen_Bruto <chr>
```